

Predicción de rotación de empleados

Autora: Beatriz Velayos · Fecha del proyecto: 11 de agosto de 2025

USO EXCLUSIVAMENTE EDUCATIVO

Este repositorio utiliza datos de ejemplo y resultados exploratorios. El modelo no está validado para evaluar, seleccionar, retener ni gestionar empleados. No debe aplicarse a datos de una empresa ni usarse para tomar decisiones sobre personas.

Resumen

El proyecto integra datos tabulares, realiza controles de calidad y un ETL con PySpark, compara modelos de clasificación con scikit-learn y presenta resultados en un prototipo de Power BI. El objetivo es demostrar un flujo formativo, no medir impacto ni proponer decisiones de Recursos Humanos.

Alcance y arquitectura

Docker Compose declara servicios locales de Jupyter, Spark Master y PostgreSQL. No hay un Worker configurado; el ETL usa Spark en modo local (local[*]) por defecto. Esta arquitectura sirve para aprender y reproducir el flujo en local, no describe una plataforma de producción.

El ETL relaciona los ficheros de ejemplo por EmployeeNumber y genera un conjunto Parquet. Los notebooks cubren análisis exploratorio, modelado, métricas, visualización e informe final.

Componentes

Preparación: PySpark y variables derivadas. Modelos: Regresión Logística, Random Forest y MLP. Evaluación homogénea OOF: ROC-AUC, PR-AUC y F1 optimizado para los tres modelos. Presentación: notebooks, artefactos versionados y prototipo Power BI.

Datos y procedencia

WA_Fn-UseC_-HR-Employee-Attrition.csv corresponde al conjunto conocido como IBM HR Analytics Employee Attrition & Performance. IBM usa un fichero con ese nombre en un tutorial de clasificación. Esto ayuda a identificar el conjunto, pero no verifica la licencia ni los derechos de esta copia. La referencia enlazada está en el README.

encuesta_clima.csv se genera para este proyecto con cinco escalas aleatorias de 1 a 5 y semilla fija 42, sin consultar la etiqueta de rotación. Es un conjunto sintético reproducible, no son respuestas de personas ni mediciones de una plantilla o empresa.


Los CSV no describen a la autora ni a su empresa. No cargar datos personales, confidenciales o de empleados reales.

Resultados y lectura correcta

Los tres modelos se compararon con predicciones out-of-fold de validación cruzada estratificada de cinco particiones. ROC-AUC: LogReg 0,819; Random Forest 0,810; MLP 0,768. PR-AUC: 0,552; 0,532; 0,484. F1 optimizado: 0,533; 0,544; 0,470. El umbral y el F1 se eligen sobre esas mismas predicciones; los resultados son exploratorios.

No se realizó validación temporal, calibración independiente, análisis formal de equidad ni validación para decisiones laborales. Las métricas se regeneraron con el código actual. El protocolo no estima de forma independiente el rendimiento futuro. Las tasas por segmento y los coeficientes describen patrones del conjunto de ejemplo. No demuestran causalidad ni se trasladan automáticamente a otra organización.

Métricas exploratorias. F1/umbral optimizados sobre las mismas predicciones OOF.



* Umbral y F1 seleccionados sobre las mismas predicciones OOF. No es una estimación independiente.

Visualizaciones

Las imágenes de esta memoria son gráficas de referencia recreadas a partir de datos y artefactos versionados; no son capturas verificadas de Power BI. El PBIX es un prototipo educativo y requiere revisión en Power BI antes de interpretar cada visual.

Reproducibilidad

1. Instala Docker Engine y Docker Compose v2. 2. Ejecuta `docker compose up -d --build` y consulta los registros de Jupyter para obtener su token temporal. 3. Genera el Parquet con `scripts/etl_attrition.py` siguiendo el comando del README. 4. Ejecuta los notebooks en el orden documentado.

Las dependencias ML se declaran mediante rangos compatibles, no como versiones exactas. Una reproducción exacta entre equipos requiere fijar versiones y verificar el entorno Docker.

La regeneración de métricas de esta revisión usó un Parquet construido localmente con las transformaciones y columnas del ETL. Docker Compose y PySpark no estaban disponibles, por lo que el ETL Spark no se ejecutó de extremo a extremo.

Conclusión

Como proyecto de bootcamp, demuestra experiencia práctica con integración de datos, ETL, clasificación, evaluación y visualización. Para el CV o un expediente interno, descríbelo como proyecto educativo con datos de ejemplo. No lo presentes como solución desplegada, validada o usada por la empresa.

Autora: Beatriz Velayos · Proyecto educativo de Big Data, Machine Learning e Inteligencia Artificial.