Resultados: las métricas y los recuentos siguientes corresponden a la ejecución reproducible canónica del proyecto.

MEMORIA DEL PROYECTO

Predicción de rotación de empleados

Datos, preparación, modelos, resultados y recomendaciones

Este proyecto educativo de Big Data y analítica de Recursos Humanos estudia la rotación `Attrition` en una empresa hipotética. Integra datos, compara clasificadores y transforma los resultados en prioridades de análisis para las áreas y la dirección.

El objetivo es preparar información reproducible, describir patrones del conjunto y proponer áreas y medidas que un equipo de negocio pueda revisar y seguir.

Recorrido del proyecto

- Control de calidad, integración y preparación de datos con PySpark.
- Análisis exploratorio y comparación de tres modelos con scikit-learn.
- Lectura de métricas, puntuaciones y tasas por departamento.
- Comunicación de hallazgos con gráficos, panel HTML interactivo y recomendaciones.

2. Datos, calidad y preparación

El archivo principal `data/raw/WA_Fn-UseC_-HR-Employee-Attrition.csv` contiene 1.470 registros y 35 columnas. Registra 237 casos “Yes” y 1.233 “No” (16,1 %); incluye departamento, puesto, viajes, horas extra, salario, antigüedad y otras características laborales. IBM publica un tutorial de contexto sobre clasificación de rotación.

El archivo `data/raw/encuesta_clima.csv` se genera con `scripts/generate_synthetic_survey.py`. Asigna cinco escalas de 1 a 5 con semilla fija 42, sin consultar Attrition, y se une al archivo principal mediante EmployeeNumber.

`scripts/check_data_quality.py` revisa presencia y nulos de la clave, duplicados, valores nulos por columna y categorías de Attrition; escribe los resultados en `/output/metrics/quality_report.json`.

Arquitectura y ETL

Docker Compose reúne Jupyter, Spark Master y PostgreSQL. Jupyter publica el puerto 8889 en la interfaz local y monta datos, scripts, notebooks, resultados y las figuras del panel. El ETL utiliza Spark en modo local (`local[*]`) y escribe en PostgreSQL cuando se invocan los scripts de persistencia.

- Lee ambos CSV, normaliza textos y columnas, convierte las escalas de encuesta y elimina duplicados por clave.
- Une todas las filas del archivo principal con la encuesta mediante una unión izquierda.
- Crea `attrition_label` y las variables `overtime_flag`, `income_yearly` y `tenure_ratio`.
- Guarda Parquet comprimido con Snappy y registra recuentos y columnas en `/output/metrics/etl_metrics.json`.

El Parquet integrado reúne 1.470 filas y 43 columnas. La memoria y el README incluyen los comandos para regenerar la encuesta, ejecutar controles y ETL y reconstruir la tabla de análisis.

Artefactos de análisis y persistencia

El control de calidad y el ETL dejan recuentos en `/output/metrics/quality_report.json` y `etl_metrics.json`. Las métricas se guardan en `/output/metrics/model_compare.json`; las puntuaciones y factores asociados, en `/output/dashboard/`; y los pipelines y curvas, en `/output/models/` y `/output/plots/`. Los scripts de persistencia cargan características y resultados en PostgreSQL.

3. Recorrido reproducible

Desde la raíz del repositorio, con Docker Engine y Docker Compose v2, se puede recorrer el proceso completo en este orden.

1. Arranque y acceso a Jupyter

```
docker compose up -d --build
docker compose logs jupyter
```

Abrir `http://localhost:8889/lab` e introducir el token temporal que aparece en los registros.

2. Generar encuesta, comprobar entradas y ejecutar ETL

```
docker compose run --rm jupyter python /scripts/generate_synthetic_survey.py \
  --input /data/raw/WA_Fn-UseC_-HR-Employee-Attrition.csv \
  --output /data/raw/encuesta_clima.csv --seed 42

docker compose run --rm jupyter python /scripts/check_data_quality.py \
  --input1 /data/raw/WA_Fn-UseC_-HR-Employee-Attrition.csv \
  --input2 /data/raw/encuesta_clima.csv \
  --key EmployeeNumber --max-null-frac 0.25

docker compose run --rm jupyter python /scripts/etl_attrition.py \
  --input1 /data/raw/WA_Fn-UseC_-HR-Employee-Attrition.csv \
  --input2 /data/raw/encuesta_clima.csv \
  --outdir /data/processed/employee_attrition.parquet
```

3. Entrenamiento y notebooks

```
docker compose run --rm jupyter python /scripts/train_ml.py \
  --input /data/processed/employee_attrition.parquet --model all

docker compose run --rm jupyter python /scripts/render_dashboard_previews.py
```

En Jupyter, abrir en orden: 01_EDA_Attrition, 02_Modelado_Baseline, 03_Modelado_DL, 05_Dashboard_KPIs y 99_Informe_Final. Al terminar: `docker compose down`.

4. Análisis y modelos

01_EDA_Attrition examina estructura, distribución de Attrition y variables numéricas y categóricas.
05_Dashboard_KPIs calcula tasas generales y por departamento, puesto, horas extra, salario y antigüedad.

El pipeline excluye identificadores, constantes y columnas de etiqueta; escala variables numéricas con StandardScaler y codifica las categóricas con OneHotEncoder. El preprocesamiento se ajusta solo con los datos de entrenamiento de cada partición.

Clasificadores

- Regresión Logística: regularización L2, ponderación balanceada y semilla 42.
- Random Forest: 300 árboles, ponderación balanced_subsample y semilla 42.
- MLP de scikit-learn: capas 64 y 32, activación ReLU, parada temprana y semilla 42.

`scripts/train_ml.py --model all` aplica validación cruzada anidada: cinco particiones externas estratificadas y, dentro de cada entrenamiento externo, tres particiones internas para seleccionar el umbral. Las observaciones externas quedan reservadas para evaluar el modelo. El proceso guarda predicciones OOF, métricas y gráficos y, después, ajusta los pipelines finales con los 1.470 registros para generar los artefactos de operación.

5. Resultados y visualizaciones

La tabla resume las métricas de `output/metrics/model_compare.json` con el mismo protocolo para los tres modelos. Valores redondeados a tres decimales:

Modelo	ROC-AUC	PR-AUC	F1 evaluado	Umbral de referencia	Exactitud a 0,5	F1 a 0,5
Regresión Logística	0,823	0,575	0,542	0,706	0,748	0,472
Random Forest	0,803	0,540	0,523	0,257	0,855	0,242
MLP	0,814	0,559	0,522	0,316	0,868	0,458

Regresión Logística obtiene el mejor resultado en las tres métricas comparativas: ROC-AUC (0,823), PR-AUC (0,575) y F1 evaluado (0,542). La exactitud se lee junto con las métricas de la clase positiva: el conjunto presenta 16,1 % de casos de rotación.

El F1 evaluado es la media de los cinco F1 externos, cada uno calculado con el umbral seleccionado en sus particiones internas. La tabla muestra además un umbral de referencia (la mediana de los cinco umbrales) y métricas adicionales a 0,5; estos valores responden a cortes distintos.

Qué muestran los gráficos

- El histograma agrupa 1.470 puntuaciones OOF de Regresión Logística en intervalos de 0,10; 747 (50,8 %) quedan por debajo de 0,30.
- La tasa observada es 20,6 % en Ventas (92/446), 19,0 % en Recursos Humanos (12/63) y 13,8 % en Investigación y Desarrollo (133/961).
- La tasa con horas extra es 30,5 % (127/416), frente a 10,4 % sin ellas (110/1.054).
- Entre los coeficientes de mayor magnitud figuran Director/a de investigación (-1,161), Representante de ventas (+1,024), horas extra: sí (+0,968) y viajes frecuentes (+0,878). Describen asociaciones del modelo y ayudan a plantear preguntas para el análisis del negocio.

Las figuras de `docs/panel/` se regeneran con `scripts/render_dashboard_previews.py` y distinguen tasas observadas y puntuaciones OOF. El panel interactivo en HTML presenta las métricas de los tres modelos, las tasas observadas, las señales OOF y los factores asociados en apartados separados.

6. Conclusiones y recomendaciones para dirección

Regresión Logística presenta los mejores valores comparativos de ROC-AUC (0,823), PR-AUC (0,575) y F1 evaluado (0,542), por lo que es la referencia principal para ordenar señales. Con su umbral de referencia (0,706) aplicado a las 1.470 puntuaciones OOF aparecen 251 señales: 110 en Ventas, 131 en Investigación y Desarrollo y 10 en Recursos Humanos. Estas prioridades se leen junto con las tasas observadas: 20,6 % en Ventas (92/446), 13,8 % en Investigación y Desarrollo (133/961) y 19,0 % en Recursos Humanos (12/63). La rotación observada alcanza 30,5 % entre quienes registran horas extra y 10,4 % entre quienes no.

Recomendaciones por área

- Ventas: comenzar el diagnóstico por su tasa observada más alta (20,6 %, 92 de 446) y sus 110 señales OOF. Revisar viajes, objetivos y carga comercial; acordar con la dirección del área un piloto con indicadores de seguimiento.
- Investigación y Desarrollo: desglosar por equipo y puesto; concentra 133 salidas observadas y 131 señales OOF, aunque su tasa sea 13,8 %. Priorizar la revisión de los equipos con mayor volumen de casos.
- Organización del trabajo: revisar turnos, cobertura y reparto de carga en las áreas con horas extra. Probar ajustes y observar la evolución de las tasas con y sin horas extra.
- Recursos Humanos: el 19,0 % corresponde a 12 salidas entre 63 personas y a 10 señales OOF. Ajustar la revisión al tamaño del área y a sus puestos.

Seguimiento para dirección

Comenzar con un piloto en Ventas y en los equipos con más horas extra, mientras se desglosa Investigación y Desarrollo por puesto y equipo. En cada revisión, presentar por área las tasas observadas, el número de salidas, las señales OOF, los denominadores y la exposición a horas extra. Incorporar comparativas mensuales cuando se disponga de datos actualizados. Asignar una persona responsable a cada medida, registrar una línea de partida y revisar mensualmente los indicadores para ajustar y ampliar las acciones que mejoren de forma sostenida.