

Predicción de rotación de empleados

Datos, preparación, modelos, resultados y recomendaciones

Este proyecto educativo de Big Data y analítica de Recursos Humanos analiza la rotación Attrition en una empresa hipotética. Integra datos, compara clasificadores y convierte los resultados en prioridades concretas para negocio y dirección.

El objetivo es preparar información reproducible, describir patrones del conjunto y proponer áreas y medidas que un equipo de negocio pueda revisar y seguir.

Recorrido del proyecto

- Control de calidad, integración y preparación de datos con PySpark.
- Análisis exploratorio y comparación de tres modelos con scikit-learn.
- Lectura de métricas, puntuaciones y tasas por departamento.
- Comunicación de hallazgos con gráficos, panel y recomendaciones.

2. Datos, calidad y preparación

El archivo principal `data/raw/WA_Fn-UseC_-HR-Employee-Attrition.csv` contiene 1.470 registros y 35 columnas. Registra 237 casos “Yes” y 1.233 “No” (16,1 %); incluye departamento, puesto, viajes, horas extra, salario, antigüedad y otras características laborales. [IBM publica un tutorial de contexto sobre clasificación de rotación](#).

El archivo `data/raw/encuesta_clima.csv` se genera con `scripts/generate_synthetic_survey.py`. Asigna cinco escalas de 1 a 5 con semilla fija 42, sin consultar Attrition, y se une al archivo principal mediante EmployeeNumber.

`scripts/check_data_quality.py` revisa presencia y nulos de la clave, duplicados, valores nulos por columna y categorías de Attrition; escribe los resultados en `/output/metrics/quality_report.json`.

Arquitectura y ETL

Docker Compose reúne Jupyter, Spark Master y PostgreSQL. Jupyter publica el puerto 8889 en la interfaz local y monta datos, scripts, notebooks, resultados y las figuras del panel. El ETL utiliza Spark en modo local (`local[*]`) y escribe en PostgreSQL cuando se invocan los scripts de persistencia.

- 1 Lee ambos CSV, normaliza textos y columnas, convierte las escalas de encuesta y elimina duplicados por clave.
- 2 Une todas las filas del archivo principal con la encuesta mediante una unión izquierda.
- 3 Crea `attrition_label` y las variables `overtime_flag`, `income_yearly` y `tenure_ratio`.
- 4 Guarda Parquet comprimido con Snappy y registra recuentos y columnas en `/output/metrics/etl_metrics.json`.

El Parquet integrado reúne 1.470 filas y 43 columnas. La memoria y el README incluyen los comandos para regenerar la encuesta, ejecutar controles y ETL y reconstruir la tabla de análisis.

Artefactos de análisis y persistencia

El control de calidad y el ETL dejan sus recuentos en `/output/metrics/quality_report.json` y `etl_metrics.json`. Las métricas de los modelos se guardan en `/output/metrics/model_compare.json`; las puntuaciones y factores asociados, en `/output/bi/`; y los pipelines y curvas en `/output/models/` y `/output/plots/`. Los scripts de persistencia cargan características y resultados en PostgreSQL.

3. Recorrido reproducible

Desde la raíz del repositorio, con Docker Engine y Docker Compose v2, se puede recorrer el proceso completo en este orden:

1. Arranque y acceso a Jupyter

```
docker compose up -d --build
docker compose logs jupyter
```

Abrir <http://localhost:8889/lab> e introducir el token temporal que aparece en los registros.

2. Generar encuesta, comprobar entradas y ejecutar ETL

```
docker compose run --rm jupyter python /scripts/generate_synthetic_survey.py \
--input /data/raw/WA_Fn-UseC_HR-Employee-Attrition.csv \
--output /data/raw/encuesta_clima.csv --seed 42

docker compose run --rm jupyter python /scripts/check_data_quality.py \
--input1 /data/raw/WA_Fn-UseC_HR-Employee-Attrition.csv \
--input2 /data/raw/encuesta_clima.csv \
--key EmployeeNumber --max-null-frac 0.25

docker compose run --rm jupyter python /scripts/etl_attrition.py \
--input1 /data/raw/WA_Fn-UseC_HR-Employee-Attrition.csv \
--input2 /data/raw/encuesta_clima.csv \
--outdir /data/processed/employee_attrition.parquet
```

3. Entrenamiento y notebooks

```
docker compose run --rm jupyter python /scripts/train_ml.py \
--input /data/processed/employee_attrition.parquet --model all

docker compose run --rm jupyter python /scripts/render_dashboard_previews.py
```

En Jupyter, abrir en orden: 01_EDA_Attrition, 02_Modelado_Baseline, 03_Modelado_DL, 05_Dashboard_KPIs y 99_Informe_Final. Al terminar: `docker compose down`.

4. Análisis y modelos

01_EDA_Attrition examina estructura, distribución de Attrition y variables numéricas y categóricas. 05_Dashboard_KPIs calcula tasas generales y por departamento, puesto, horas extra, salario y antigüedad.

El pipeline excluye identificadores, constantes y columnas de etiqueta; escala variables numéricas con StandardScaler y codifica las categóricas con OneHotEncoder. El preprocesamiento se ajusta dentro de cada pliegue de validación.

Clasificadores

- Regresión logística: regularización L2, ponderación balanceada y semilla 42.
- Random Forest: 300 árboles, ponderación balanced_subsample y semilla 42.
- MLP de scikit-learn: capas 64 y 32, activación ReLU, parada temprana y semilla 42.

scripts/train_ml.py --model all calcula probabilidades OOF con validación cruzada estratificada de cinco particiones, guarda métricas y gráficos y ajusta cada pipeline con el conjunto completo para generar sus artefactos finales.

5. Resultados y visualizaciones

La tabla resume las métricas de `output/metrics/model_compare.json` con el mismo protocolo para los tres modelos. Valores redondeados a tres decimales:

Modelo	ROC-AUC	PR-AUC	F1 comparativo	Umbral	Exactitud a 0,5	F1 a 0,5
Regresión logística	0,819	0,552	0,533	0,732	0,753	0,479
Random Forest	0,810	0,532	0,544	0,210	0,856	0,248
MLP	0,768	0,484	0,470	0,238	0,857	0,305

Regresión Logística ofrece la mejor ordenación global según ROC-AUC y PR-AUC; Random Forest obtiene el F1 comparativo más alto. La tasa global de Attrition es 16,1 %, por lo que la exactitud se interpreta junto con las métricas de la clase positiva.

Qué muestran los gráficos

- El histograma agrupa 1.470 puntuaciones OOF de Regresión Logística en intervalos de 0,10; 773 (52,6 %) están por debajo de 0,30.
- La tasa observada es 20,6 % en Ventas (92/446), 19,0 % en Recursos Humanos (12/63) y 13,8 % en Investigación y Desarrollo (133/961).
- La tasa con horas extra es 30,5 % (127/416), frente a 10,4 % sin ellas (110/1.054).
- Entre los coeficientes de mayor magnitud aparecen representante de ventas (+1,070), viajes frecuentes (+0,856) y director/a de investigación (−1,121); sirven para orientar preguntas de negocio.

Las figuras de `docs/powerbi/` se regeneran con `scripts/render_dashboard_previews.py` y resumen tasas y puntuaciones; el PBIX organiza indicadores por departamento, puesto y horas extra para consultarlos en Power BI Desktop.

6. Conclusiones y recomendaciones para dirección

Los resultados ofrecen criterios concretos para ordenar la actuación. Regresión Logística presenta la mejor capacidad de ordenación global (ROC-AUC 0,819; PR-AUC 0,552), mientras que Random Forest obtiene el F1 comparativo más alto (0,544). La lectura por áreas combina tasas y volumen de señales. Al aplicar el umbral comparativo 0,732 a las predicciones OOF de Regresión Logística aparecen 228 señales: 104 en Ventas, 115 en Investigación y Desarrollo y 9 en Recursos Humanos. Ventas registra 20,6 % de rotación; Investigación y Desarrollo, 133 salidas observadas (13,8 %); y Recursos Humanos, 19,0 % (12 de 63). Además, la tasa es 30,5 % en los registros con horas extra y 10,4 % en los demás.

Recomendaciones por área

- 1 Ventas: iniciar aquí el diagnóstico por su tasa más alta (92 de 446) y sus 104 señales. Revisar viajes, objetivos, carga y experiencia en los puestos comerciales; acordar con la dirección del área un piloto y seguir sus indicadores.
- 2 Investigación y Desarrollo: priorizar el desglose por equipo y puesto, pues concentra 133 salidas observadas y 115 señales aunque su tasa sea 13,8 %. Dirigir el acompañamiento a los equipos con mayor volumen de casos.
- 3 Organización del trabajo: revisar turnos, cobertura y reparto de carga en las áreas con horas extra. Probar ajustes y observar la evolución de las tasas con y sin horas extra.
- 4 Recursos Humanos: considerar que su 19,0 % corresponde a 12 salidas entre 63 personas y a 9 señales. Acordar una revisión ajustada al tamaño del área y a sus puestos.

Seguimiento para dirección

Comenzar con un piloto en Ventas y en los equipos con más horas extra, mientras se desglosa Investigación y Desarrollo por puesto y equipo. En el panel, presentar por área y periodo la tasa, el número de salidas, las señales, el denominador y la exposición a horas extra. Asignar una persona responsable a cada medida, registrar una línea de partida y revisar mensualmente los indicadores para ajustar y ampliar las acciones que mejoren de forma sostenida.

Los coeficientes de representantes de ventas y viajes frecuentes ayudan a formular preguntas para el diagnóstico comercial. La conclusión ejecutiva es concentrar primero la revisión donde coinciden una tasa alta, más señales o un mayor volumen de casos, y dar seguimiento a las medidas con indicadores comunes.